

厦门大学计算机科学与技术系本科生课程

数据库系统原理

(2025-2026 学年春季学期)

期末大实验说明

主讲教师：张东站，林子雨

E-mail: ziyulin@xmu.edu.cn

二零二六年五月

一、作业题目

数据分析智能体的设计与实现。

二、作业目的

综合运用 Python 数据处理、关系数据库建模、SQL 查询、数据可视化和大模型应用开发技术，围绕真实数据集，设计并实现一个能够回答业务分析问题的数据智能体（Data Agent）。

通过本作业，学生应掌握真实数据集下载、抽样、清洗、转换、建库、查询、分析、可视化和大模型辅助开发的完整流程，并能够解释系统运行过程和分析结果。

三、作业性质

必做。作为评定期末总成绩的依据。

本作业要求学生组队完成，采用团队合作形式，团队人数 2-3 人（最少 2 人，最多 3 人）。不得抄袭他人代码、报告、截图或网上完整项目。可以使用大模型或 AI 编程工具辅助完成，但必须在实验报告中说明使用方式、主要提示词以及人工修改内容。

四、作业考核方法

作业成绩评定方法如下：

- （1）不按时交作业、所提交的作业无法打开或抄袭他人作业：零分。
- （2）作业评分范围：0-100 分。

作业核心考察内容如下：

- （1）数据处理与建库：考察数据获取、抽样、清洗、表结构设计、数据导入和查询验证。
- （2）数据智能体 核心功能：考察数据库连接、表结构读取、自然语言问题理解、SQL 生成、SQL 执行和结果解释。
- （3）业务分析能力：考察是否能够围绕真实问题进行分析。
- （4）可视化与结果展示：考察是否至少展示一个真实查询结果对应的图表或页面。
- （5）实验报告与运行截图：考察报告结构、过程说明、运行截图和复现说明。

五、提交日期与方式

- 1、提交日期。学生应在指定截止日期（等待老师通知）之前提交作业压缩包。
- 2、提交的内容为压缩文件 RAR 文件，最后把压缩包文件提交到厦门大学数字化教学平台上。
- 3、文件名命名为“姓名学号.rar”（组长的姓名和学号），例如“王小明 23020191152890.rar”。只需要组长提交，组员不用提交。

4、文件夹中需要包含组员名单（含组长和组员的学号和姓名、任务分工）、数据集、实验报告（WORD 文档）、工程文件（含代码）以及其他有必要提交的文档。实验报告必须详细，使教师可以根据提交材料复现实验主要内容。

六、作业工具和环境要求

（1）操作系统自由选择。

（1）必须使用 Python 语言完成数据处理、建库脚本和 Data Agent 主要程序。

（2）必须使用 pandas 完成数据读取、清洗、抽样或字段转换等预处理工作。

（3）必须使用 SQLite、MySQL 或 PostgreSQL 之一建立关系数据库。

（4）必须使用 LangChain 开发框架连接数据库并实现自然语言查询能力。

（5）必须至少在一个环节中用到大模型工具，例如自然语言问题理解、SQL 生成、SQL 检查、查询结果解释、图表说明生成或代码辅助编写。

（6）可以使用在线大模型 API，也可以使用本地模型服务，例如 Ollama、LM Studio、vLLM 等。

（7）可以使用 Matplotlib、Pyecharts、Plotly、ECharts、Streamlit、Gradio、Flask、FastAPI 或其他工具实现可视化和界面。

相关软件版本要求如下：

（1）Python: 3.x;

（2）pandas: 1.x 及以上版本;

（3）LangChain: 以实际安装版本为准;

（4）数据库: SQLite / MySQL / PostgreSQL 任选一种;

（5）如果同学使用了其他软件，请一定在软件版本号 TXT 文件中明确列出。

七、作业内容和要求

完整实现数据处理、建库、数据智能体（Data Agent）、业务分析和可视化展示全流程，具体如下：

1. 数据集获取

自行到网络上寻找一个公开数据集，比如，可以到 Kaggle 平台获取数据集。数据集类型自由选择，比如可以是电商数据集、篮球比赛数据集等等。

2. 数据预处理

必须使用 Python 完成数据预处理，建议使用 pandas。数据预处理的参考任务如下（不是必须实现下面所有任务，是参考）：

（1）读取原始 CSV 文件。

（2）检查字段名称和字段类型。

（3）检查缺失值并说明处理方式。

（4）去除明显重复记录。

(5) 转换字段类型，比如，电商数据集需要转换订单时间、支付金额、商品价格、运费、评价分数等字段。

(6) 根据需要抽样并保留表之间的关联关系。

(7) 生成清洗后的 CSV 文件或直接写入数据库。

如果某些字段存在缺失值，需要说明缺失原因和处理方式。

3. 数据库设计与建库

需要将处理后的数据导入关系数据库。

建库要求包括：提供建表 SQL 或建库脚本，提供数据导入脚本，合理设置字段类型，为常用查询字段建立索引，通过 SQL 查询验证数据成功导入，并在实验报告中说明表结构和表之间的关系。

4. 数据智能体（Data Agent）实现

需要基于 Python、LangChain 和大模型实现一个数据分析智能体（Agent）。智能体至少需要具备以下能力：

- (1) 连接数据库。
- (2) 读取或理解数据库表结构。
- (3) 接收自然语言业务问题。
- (4) 选择相关数据表。
- (5) 生成只读 SQL 查询。
- (6) 执行 SQL 查询。
- (7) 返回查询结果。
- (8) 根据查询结果生成自然语言分析结论。

例如，对于电商数据集，用户可以输入以下问题：

- 每个月的订单量是多少？
- 销售额最高的 10 个商品类目是什么？
- 不同支付方式的订单金额有什么差异？
- 延迟送达订单的平均评分是否更低？
- 哪些卖家的销售额最高？

5. 业务分析要求

智能体需要能够围绕数据集中的具体问题，开展分析。比如，对于电商数据集，下列五类问题可以作为的参考业务场景：

(1) 订单经营分析：每月订单量、销售额、订单状态分布、订单增长趋势、地区订单分布等。

(2) 商品和类目分析：销售额最高类目、销量最高类目、平均客单价、平均评分、商品重量与运费关系等。

(3) 支付分析：不同支付方式的订单数量、平均支付金额、信用卡分期数和订单金额关系等。

(4) 物流履约分析：下单到送达耗时、延迟送达比例、不同州配送时间、卖家与客户同州配送情况等。

(5) 客户满意度分析：整体平均评分、低评分类目、延迟送达与评分关系、低评分卖家、有无文字评论与评分关系等。

每个运行案例建议包含：自然语言问题、智能体生成的 SQL、SQL 查询结果、智能体的自然语言解释和运行截图。

6. 可视化要求

必须至少实现一个真实分析结果的可视化展示。比如，对于电商数据集，可视化内容可以包括每月订单量趋势图、商品类目销售额柱状图、不同支付方式金额分布图、订单评分分布图、延迟送达比例图或客户州分布图等。报告中需要包含可视化截图，并说明图表对应的数据来源和分析结论。

7. 大模型使用要求

整个作业必须至少有一个环节使用大模型工具。大模型可以用于自然语言问题理解、SQL 生成、SQL 检查、查询结果解释、图表说明生成或代码辅助编写。实验报告必须说明使用的大模型或 AI 编程工具名称、使用场景、关键提示词、运行截图、大模型输出是否经过人工修改，以及大模型在作业中发挥了什么作用。

八、参考资料

- 1、Kaggle 数据集获取网站：<https://www.kaggle.com>
- 2、LangChain SQL Agent 文档：<https://docs.langchain.com/oss/python/langchain/sql-agent>
- 3、LangChain SQLDatabaseToolkit 文档：
https://docs.langchain.com/oss/python/integrations/tools/sql_database/
- 4、SQLite 官方文档：<https://www.sqlite.org/docs.html>
- 5、Pandas 官方文档：<https://pandas.pydata.org/docs/>
- 6、Matplotlib 官方文档：<https://matplotlib.org/stable/users/index.html>
- 7、Streamlit 官方文档：<https://docs.streamlit.io/>

特别注意：本作业不能只提交原始 CSV 文件，必须提交可复现的数据处理脚本和建库脚本；不能只展示大模型聊天结果，必须展示数据库查询过程和真实查询结果；智能体的回答必须基于 SQL 查询结果，不能只凭大模型常识编造结论。